Case: California Housing – modellering som beslutsunderlag

Student: Wendy Mermet (Python version 3.11.9)

1) Mål och valt spår

Kunden vill kunna snabbt bedöma om ett nytt område sannolikt är ett högprisområde, baserat på tillgängliga egenskaper som geografi, hushåll och inkomstnivåer.

- **Spår B – Klassificering (identifiera högprisområden):** Jag valde klassificering eftersom jag tycker det är mer intressant att arbeta med, och det är en metod som ofta används i affärssammanhang för att prioritera resurser och fatta beslut baserat på sannolikheter.
- **Mål:**
  - Skapa binär target (`high_value`) – topp 20% = 1, övriga = 0
  - Träna modell endast på övriga features, utan `median_house_value`
  - Prioritera resurser genom att identifiera högprisområden
  - Minimera risken att missa ett högprisområde

---

2) Kort data-insikt (EDA)

- Saknade numeriska features → median
- Saknade kategoriska features → mest frekvent
- Targetfördelning: 20% positiv, 80% negativ (obalanserad)
- Fokus på recall för att minimera falska negativa

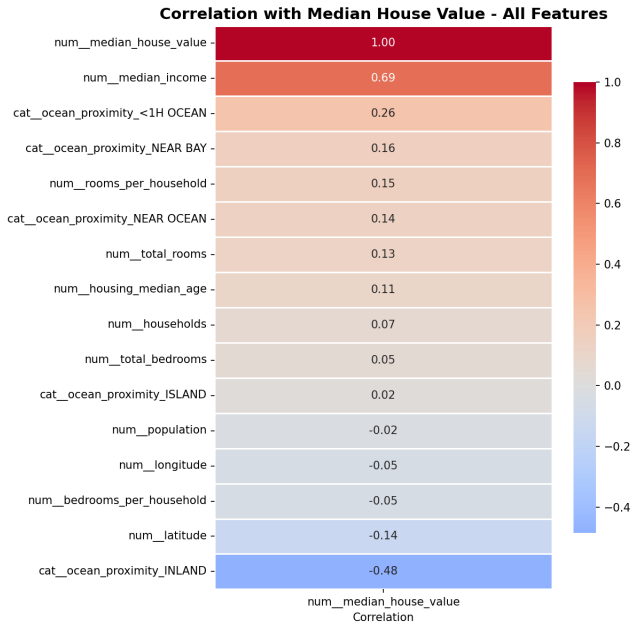

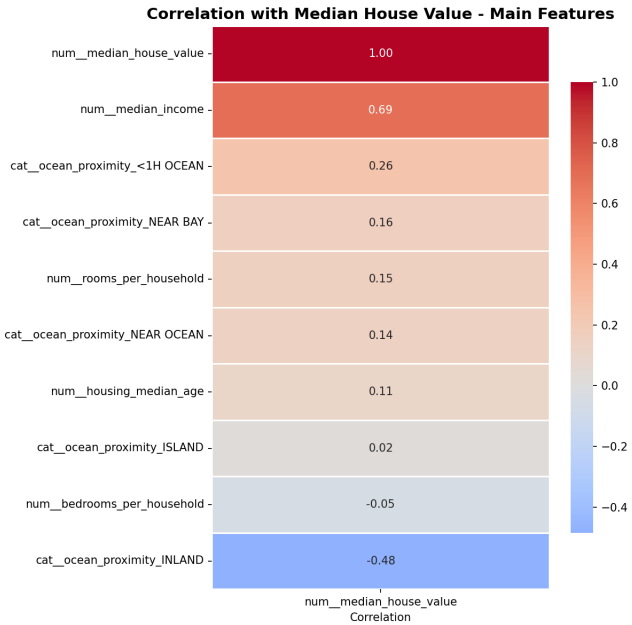

---

3) Metod (ML-flöde)

- Skapande av nya features (`rooms_per_household`, `bedrooms_per_household`) och målvariabeln som indikerar topp 20% av husvärdena
- Datan delas i X och y, sedan i tränings- och testset med `stratify=y`
- Transformatorer och skalare appliceras på numeriska och kategoriska features, irrelevanta features tas bort
- Tre modeller tränas via pipelines – Logistic Regression (baseline), Decision Tree och Random Forest – med 5-faldig CV och `recall` som metric
- Bästa modellerna optimeras med GridSearchCV, slutmodellen väljs baserat på optimala parametrar och utvärderas på testdata med samma preprocessing för att undvika dataläckage

---

4) Resultat

- **Jämförelse av modeller:**
  - Baseline: Decision Tree & Random Forest bäst (recall ~0.58), Logistic Regression lägst (~0.54)
  - Efter tuning: **Decision Tree bäst med recall 0.754**
- **Resultat efter tuning:**
  - Störst förbättring jämfört med baseline
  - Stabil recall ~0.75 → identifierar majoriteten av högprisområden

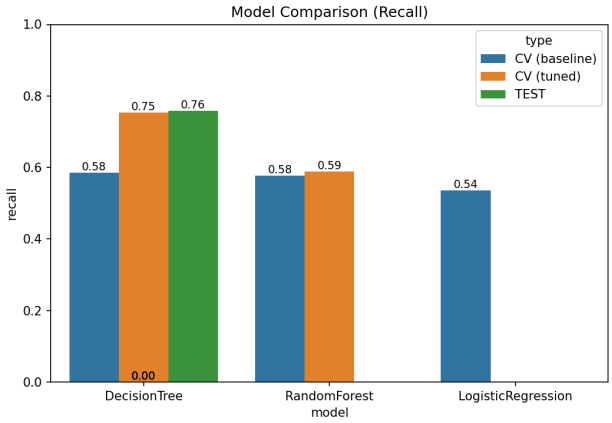

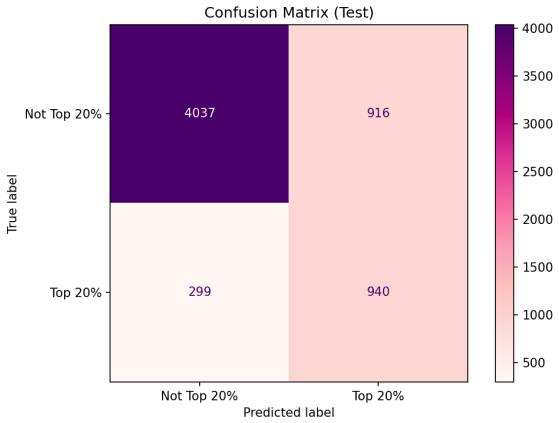

---

5) Rekommendation

- **Vald modell:** Decision Tree
- **Bästa parametrar:**
  `| class_weight | criterion | max_depth | max_features | min_samples_leaf | min_samples_split | | balanced | entropy | 10 | log2 | 6 | 2 |`
- **Resultat:**
  - CV Recall (tuned): 0.754
  - Test Recall: 0.759, Accuracy: 0.804, Precision: 0.506, F1: 0.607
- **Motivering:**
  - Högst recall på både CV och testdata
  - Fokuserar på att minimera falska negativa
  - Tolkbar modell → möjlighet att analysera fel via PCA-komponenter
  - Applicerbar på nya områden med korrekt preprocessing

---

6) Risker och begränsningar

- **Typiska fel:** FN → missar områden där geografi väger tyngre än boendestandard; FP → överskattar områden med stark socioekonomisk signal
- **Externa risker:** Historiska data fångar inte stadsplanering, marknadstrender, invånares initiativ, politisk stabilitet eller ekonomiska kriser
- **Fel vid användning:** Dataläckage vid felaktig applicering av Scaller/Transformer före split → överoptimistiska prestanda
- **Nästa steg:** Inkludera fler externa faktorer, testa alternativa modeller, säkerställa korrekt pipeline

---

7) Oövervakad inlärning

- **Definition:** Algoritmen hittar mönster utan target
- **Syfte:** Förstå områdesstruktur, identifiera grupper och avvikare
- **Verktyg:** PCA → reducerar dimensioner, KMeans → grupperar observationer
- **PCA-resultat:** PC1–PC4 → 92,7% av variationen; PC1: `rooms_per_household`, `bedrooms_per_household`; PC2: `median_income`, `housing_median_age`; PC4: `ocean_proximity`

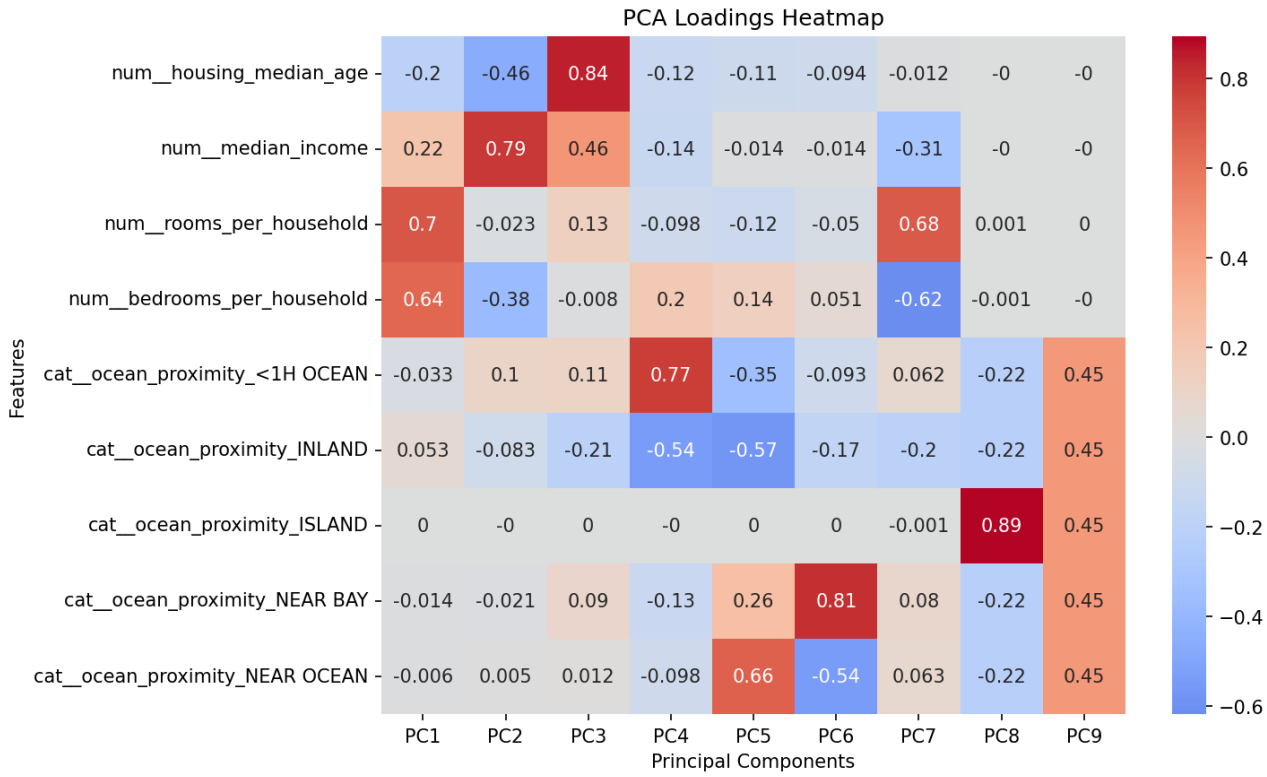

---

8) Självreflektion

- **Styrkor:** Förmåga att systematiskt gå igenom problemet, fokusera på ett tydligt mål och presentera resultat på ett lättförståeligt sätt
- **Svårast:** Visualisering och tolkning av PCA-komponenter; säkerställa korrekt features genom hela pipeline
- **Självskattning: VG** – alla G-krav uppfyllda; extra VG-krav genomförda (oövervakad inlärning, fördjupad analys, kritisk diskussion)